ĐỀ TÀI NHẬN DIỆN QUẢ SẦU RIÊNG CHÍNH HAY KHÔNG

1. GIỚI THIỆU (INTRODUCTION)

1.1. Bối cảnh và Đặt vấn đề

Sầu riêng (*Durio zibethinus*) là một trong những loại cây ăn quả nhiệt đới có giá trị kinh tế và xuất khẩu cao nhất tại khu vực Đông Nam Á. Trong chuỗi cung ứng nông sản hiện đại, việc phân loại độ già (maturity classification) khi thu hoạch và đánh giá độ chín (ripeness assessment) trước khi phân phối đóng vai trò quyết định đến chất lượng cảm quan, thời gian bảo quản và giá trị thương phẩm. Tuy nhiên, khác với các loại trái cây có vỏ mỏng dễ quan sát sự thay đổi màu sắc trực quan, sầu riêng sở hữu lớp vỏ dày, cứng và phủ đầy gai nhọn. Các biến đổi sinh hóa cốt lõi bên trong — chẳng hạn như quá trình chuyển hóa tinh bột thành đường, sự mềm hóa cấu trúc thịt quả, sự hình thành khoảng rỗng khí giữa múi và vỏ trong, cũng như quá trình sinh nhiệt và phát tán hợp chất hữu cơ dễ bay hơi — gần như bị che khuất khỏi tầm nhìn thông thường.

Trong thực tiễn sản xuất, việc kiểm định chất lượng sầu riêng vẫn phụ thuộc nặng nề vào hai phương pháp truyền thống:

1. **Kiểm tra phá hủy (Destructive testing):** Cắt hoặc khui vỏ một số quả đại diện trong lô hàng để kiểm tra trực tiếp màu sắc và độ ngọt của cơm. Phương pháp này gây thất thoát sản lượng thương phẩm và không thể áp dụng đại trà trên từng cá thể quả.
2. **Đánh giá cảm quan thủ công (Manual sensory evaluation):** Dựa vào kinh nghiệm của thương lái hoặc công nhân phân loại thông qua việc quan sát hình thái gai/cuống, ngửi mùi và dùng dao gõ vào vỏ để lắng nghe âm sắc phản hồi. Cách tiếp cận này mang tính chủ quan cao, thiếu tính nhất quán, dễ sai lệch khi làm việc với cường độ lớn và không thể mở rộng quy mô tự động hóa công nghiệp.

Sự phát triển của Trí tuệ nhân tạo (AI) và công nghệ cảm biến không phá hủy (non-destructive sensing) đã mở ra hướng giải quyết mới cho bài toán này. Tuy nhiên, các nghiên cứu hiện tại đang đối mặt với một **nghịch lý lớn giữa độ chính xác và tính khả thi triển khai (Accuracy – Deployability Trade-off)**:

- **Các hệ thống chỉ dựa trên thị giác máy tính (Vision-only RGB Systems):** Có chi phí phần cứng cực thấp, dễ dàng tích hợp lên điện thoại thông minh hoặc camera băng chuyền. Thế nhưng, do thiếu dữ liệu về cấu trúc vật lý bên trong, các mô hình chỉ nhìn ảnh RGB thường xuyên bị nhầm lẫn ở các giai đoạn chuyển tiếp (ví dụ: quả già đạt chuẩn thu hoạch so với quả non, hoặc quả chín tới so với quả chín ép), đồng thời dễ bị hiện tượng học vẹt (overfitting) vào phông nền và điều kiện chiếu sáng.
- **Các hệ thống đa phương thức (Multi-modal Sensor Systems):** Kết hợp đồng thời nhiều nguồn tín hiệu như âm thanh gõ cơ học (Acoustic Knock), ảnh nhiệt hồng ngoại (Thermal

Imaging), ảnh đa phổ (Multispectral Imaging) và các thông số cảm biến lý - hóa. Dù đạt độ chính xác vượt trội nhờ nhìn nhận quả sầu riêng dưới nhiều chiều vật lý, việc trang bị đồng bộ toàn bộ hệ thống cảm biến đắt đỏ và buồng đo tiêu chuẩn tại từng điểm thu mua hay trên thiết bị cầm tay của nông dân là điều bất khả thi về mặt chi phí lẫn vận hành.

1.2. Động lực nghiên cứu và Giải pháp đề xuất

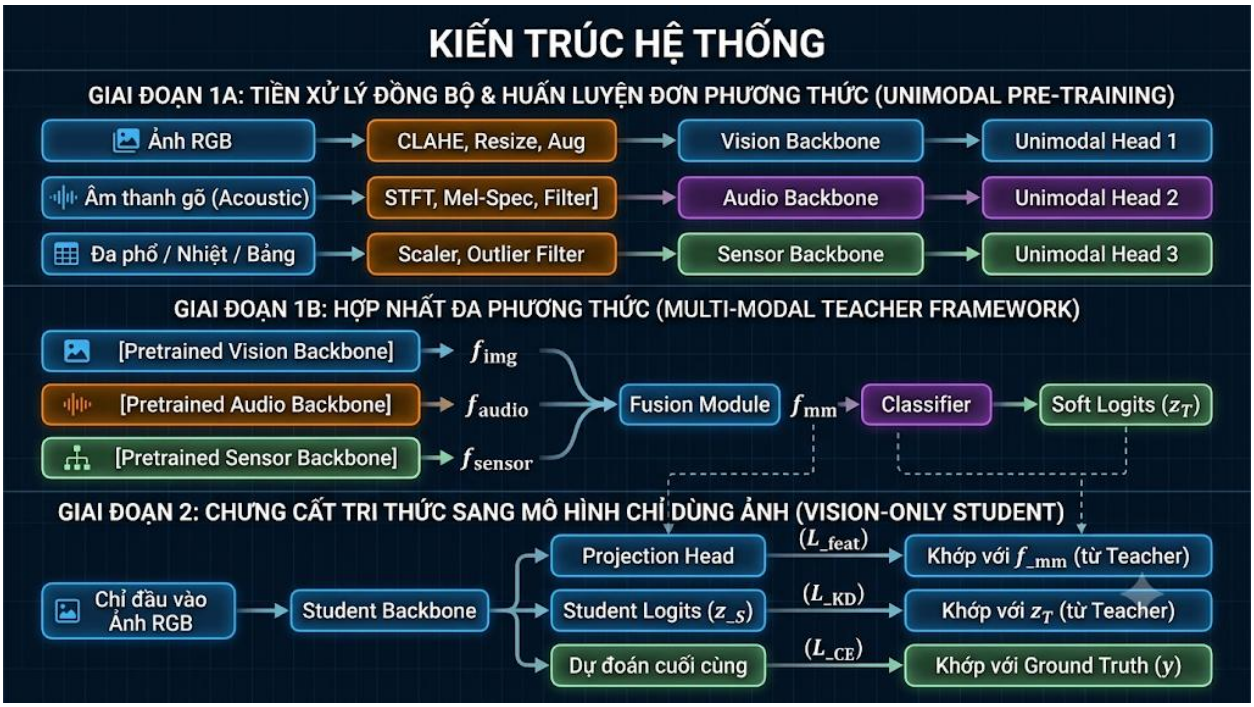
Để phá vỡ rào cản giữa hiệu năng của hệ thống đa cảm biến và tính tiện dụng của hệ thống camera đơn kênh, dự án này đề xuất xây dựng một framework tổng thể dựa trên nguyên lý **Học với thông tin đặc quyền (Learning Using Privileged Information - LUPI)** kết hợp với kỹ thuật **Chưng cất tri thức liên phương thức (Cross-Modal Knowledge Distillation - CMKD)**.

Khai thác bộ dữ liệu đa phương thức *Multi-Modal Sensor Data for Durian Fruit Maturity Classification and Ripeness Assessment* trên Zenodo — bao gồm các phép đo đồng bộ từ ảnh RGB, bản ghi âm thanh gõ (acoustic knock recordings), ảnh nhiệt (thermal) và dữ liệu đa phổ/bảng (multispectral/tabular) — ý tưởng cốt lõi của dự án được đặt trên giả thuyết khoa học: **Mặc dù các biến đổi cơ - lý - nhiệt bên trong quả sầu riêng rất khó nhận biết trực tiếp bằng mắt thường, chúng vẫn để lại những dấu hiệu hình thái vi mô trên bề mặt vỏ (như độ giãn nở của rãnh gai, vi cấu trúc vùng đĩa cuống, sự chuyển dịch sắc độ tinh vi ở chân gai)**. Một mô hình thị giác thông thường khi chỉ học với nhãn cứng (Hard Labels: Chín / Chưa chín) sẽ không đủ định hướng để tìm ra các đặc trưng vi mô này. Ngược lại, nếu có một mô hình Đa phương thức đóng vai trò là "Chuyên gia toàn diện" (Teacher Model) được huấn luyện trên toàn bộ các kênh cảm biến để dẫn dắt, mô hình Thị giác (Vision-Only Student Model) có thể học cách căn chỉnh không gian biểu diễn của ảnh RGB tiệm cận với không gian đặc trưng đa cảm biến.

Như vậy, dữ liệu âm thanh gõ, nhiệt và đa phổ chỉ cần xuất hiện ở **pha huấn luyện (Training Phase)** dưới dạng thông tin đặc quyền. Ở **pha suy luận thực tế (Inference Phase)**, hệ thống hoàn toàn loại bỏ các cảm biến phụ trợ, chỉ sử dụng duy nhất một mô hình nhận đầu vào là **ảnh RGB** nhưng mang trong mình năng lực phân tách tương đương với sự am hiểu đa giác quan của Teacher.

1.3. Kiến trúc hệ thống và Quy trình thực thi chi tiết

Hệ thống được thiết kế theo kiến trúc phân tầng chặt chẽ gồm 3 giai đoạn kỹ thuật nối tiếp nhau:



1.3.1. Quản lý dữ liệu đồng bộ theo cấp độ quả và Tiền xử lý chuyên biệt

Để đảm bảo tính toàn vẹn khoa học và ngăn chặn triệt để hiện tượng rò rỉ dữ liệu (Data Leakage) khi một quả sầu riêng được chụp nhiều góc hoặc gõ nhiều lần, toàn bộ dữ liệu được quản lý thông qua một bảng chỉ mục thống nhất khóa chặt theo mã định danh quả (fruit_id). Việc phân chia tập dữ liệu Huấn luyện (Train), Kiểm định (Validation) và Kiểm tra (Test) được thực hiện theo chiến lược **Stratified Group Split cấp độ quả** sau khi hoàn tất phân tích khám phá (EDA) và loại bỏ ngoại lai (outliers) trên cả 3 nhánh:

- **Nhánh Thị giác (RGB Image Branch):** Áp dụng cân bằng sáng cục bộ thích ứng (CLAHE) để làm nổi bật kết cấu rãnh gai và vùng cuống, kết hợp các phép biến đổi không gian (Random Crop, Resize) và biến đổi màu sắc kiểm soát (Color Jitter) cùng các kỹ thuật chống lệch lớp (Focal Loss / Class Weighting).
- **Nhánh Âm học (Acoustic Knock Branch):** Xử lý tín hiệu dao động cơ học khi gõ vào vỏ quả bằng cách cắt bỏ khoảng lặng và lọc nhiễu môi trường, sau đó biến đổi Fourier thời gian ngắn (STFT) sang biểu đồ phổ **Log-Mel Spectrogram** kích thước cố định. Áp dụng tăng cường dữ liệu trên miền tần số - thời gian (SpecAugment: Time Masking và Frequency Masking) để tăng tính bền vững.
- **Nhánh Cảm biến / Quang phổ / Nhiệt (Sensor, Multispectral & Thermal Branch):** Phân tích tương quan đặc trưng, lọc nhiễu bức xạ nhiệt nền, xử lý giá trị khuyết thiếu và chuẩn hóa phân phối (StandardScaler/MinMaxScaler chỉ khớp tham số trên tập Train) nhằm đưa các đại lượng vật lý khác đơn vị về cùng một miền giá trị ổn định.

Trên cơ sở đó, hệ thống xây dựng 3 bộ nạp dữ liệu độc lập (ImageDataset, AudioDataset, SensorDataset) phục vụ huấn luyện riêng lẻ, đồng thời đóng gói thành một bộ nạp đa phương

thức (MultimodalDataset) trả về cấu trúc tuple 5 thành phần đồng bộ tuyệt đối: (img, audio, sensor, label, fruit_id).

1.3.2. Giai đoạn 1: Huấn luyện Unimodal Baselines và Xây dựng Multi-Modal Teacher

Trong học máy đa phương thức, nếu huấn luyện đồng thời toàn bộ các nhánh từ trạng thái khởi tạo ngẫu nhiên, hệ thống sẽ gặp phải hiện tượng **Lấn át phương thức (Modality Dominance / Shortcut Learning)**. Do tín hiệu âm thanh tần số gõ và thông số quang phổ/nhiệt có mối tương quan trực tiếp và dễ hội tụ hơn nhiều so với dữ liệu ảnh 2D phức tạp, hàm mất mát tổng sẽ giảm nhanh chóng dựa vào nhánh âm thanh/cảm biến, khiến đạo hàm (gradient) truyền ngược về nhánh ảnh bị triệt tiêu sớm.

Để giải quyết vấn đề này, quy trình xây dựng Teacher được tách thành hai bước:

1. **Huấn luyện đơn phương thức (Unimodal Pre-training):** Huấn luyện độc lập 3 mô hình phân loại trên từng kênh dữ liệu riêng biệt. Bước này vừa thiết lập các **mốc đối chuẩn thực nghiệm (Unimodal Baselines)** để định lượng giá trị của từng loại cảm biến, vừa buộc mỗi Backbone phải tự tối đa hóa năng lực trích xuất đặc trưng trên miền dữ liệu của chính nó.

2. **Hợp nhất đa phương thức (Multi-Modal Fusion & Joint Fine-tuning):** Loại bỏ tầng phân loại rời rạc của 3 mô hình đơn lẻ và giữ lại các Backbone đã hội tụ để trích xuất 3 vector đặc trưng $f_{img} \in \mathbb{R}^{d_1}$, $f_{audio} \in \mathbb{R}^{d_2}$ và $f_{sensor} \in \mathbb{R}^{d_3}$. Ba vector này được đưa vào **Khối Hợp nhất (Fusion Module)** — sử dụng kiến trúc *Concatenation MLP* hoặc cơ chế chú ý chéo (*Cross-Attention / Gated Multimodal Unit*) — nhằm học sự tương tác phi tuyến giữa hình thái vỏ, độ rỗng âm học và phản hồi quang phổ/nhiệt, tạo ra vector biểu diễn đa phương thức hợp nhất $f_{mm} \in \mathbb{R}^{d_{mm}}$. Quá trình huấn luyện Teacher sử dụng chiến lược đóng băng khởi động (Warm-up Freeze) trong các epoch đầu để ổn định khối Fusion, sau đó mở khóa tinh chỉnh toàn mạng với **tốc độ học phân tầng (Differential Learning Rates)** (giữ learning rate cực nhỏ 10^{-5} cho các Backbone và 10^{-3} cho khối Fusion).

1.3.3. Giai đoạn 2: Chưng cất tri thức liên phương thức sang Vision-Only Student

Sau khi mô hình Multi-Modal Teacher đạt trạng thái hội tụ tối ưu (với kỳ vọng vượt xa hiệu năng của các nhánh đơn lẻ), toàn bộ trọng số của Teacher được đóng băng hoàn toàn (requires_grad = False). Mô hình **Student** — được thiết kế gọn nhẹ và **chỉ nhận đầu vào duy nhất là ảnh RGB** — sẽ được huấn luyện dưới sự dẫn dắt song song của nhãn thực tế và tri thức từ Teacher.

Trong mỗi bước huấn luyện, cùng một mẫu quả sầu riêng từ MultimodalDataset sẽ cung cấp (img, audio, sensor) cho Teacher để trích xuất vector ẩn f_{mm} và vector logits $z_{teacher}$, trong khi Student chỉ nhận img để sinh ra vector đặc trưng thị giác $f_{img}^{(S)}$ và logits $z_{student}$. Quá trình tối ưu hóa Student được điều khiển bởi hàm mất mát tổng hợp gồm 3 thành phần:

$$L_{total} = \alpha L_{CE}(y, \hat{y}_{student}) + \beta L_{KD}(z_{student}, z_{teacher}) + \gamma L_{feat}\left(\phi\left(f_{img}^{(S)}\right), f_{mm}\right)$$

Trong đó:

- **Hàm mất mát nhãn cứng (L_{CE}):** Là hàm Cross-Entropy tiêu chuẩn giữa dự đoán của Student $\hat{y}_{student} = \sigma(z_{student})$ và nhãn thực tế y, đảm bảo mô hình bám sát mục tiêu phân loại gốc.
- **Chưng cất dựa trên phản hồi đầu ra (L_{KD} - Response-based Logit Matching):** Sử dụng độ phân kỳ Kullback-Leibler (KL Divergence) với tham số nhiệt độ làm mềm T để ép phân phối xác suất đầu ra của Student khớp với "nhãn mềm" (Soft Targets) của Teacher:

$$L_{KD} = T^2 \cdot D_{KL}\left(\sigma\left(\frac{z_{student}}{T}\right) \parallel \sigma\left(\frac{z_{teacher}}{T}\right)\right)$$

Thành phần này truyền đạt "tri thức tối" (dark knowledge) về mức độ tương đồng giữa các lớp (ví dụ: một quả sầu riêng ở trạng thái chuyển tiếp được Teacher đánh giá 65% Chín và 35% Chưa chín), giúp Student tránh đưa ra các ranh giới quyết định cứng nhắc và giảm thiểu hiện tượng quá khớp.

- **Căn chỉnh không gian biểu diễn ẩn (L_{feat} - Feature-based Latent Alignment):** Sử dụng một tầng chiếu thích ứng $\phi(\cdot)$ (Projection Head) để ánh xạ vector đặc trưng của mạng ảnh Student $f_{img}^{(S)}$ về cùng số chiều với vector hợp nhất f_{mm} của Teacher, sau đó tối thiểu hóa khoảng cách Cosine hoặc sai số bình phương trung bình (MSE):

$$L_{feat} = 1 - \frac{\phi\left(f_{img}^{(S)}\right) \cdot f_{mm}}{\|\phi\left(f_{img}^{(S)}\right)\|_2 \, \|f_{mm}\|_2}$$

Đây là cầu nối kỹ thuật quan trọng nhất của dự án: bằng cách ép vector đặc trưng rút ra từ ảnh RGB phải nằm gần vector chứa thông tin âm thanh và quang phổ/nhiệt trong không gian ẩn, các bộ lọc tích chập (convolutional/attention filters) của Student buộc phải tự điều chỉnh để tập trung vào đúng những vùng hình thái trên vỏ quả có mối liên hệ vật lý mật thiết nhất với độ chín bên trong.

1.4. Mục tiêu và Đóng góp chính của Dự án

Thông qua việc hiện thực hóa kiến trúc trên, dự án hướng tới 4 đóng góp cốt lõi về mặt kỹ thuật và thực nghiệm:

1. **Chuẩn hóa Pipeline dữ liệu đa phương thức không rò rỉ:** Xây dựng quy trình EDA, lọc nhiễu đa kênh và thiết kế hệ thống DataLoader đồng bộ theo định danh từng quả (fruit_id) trên bộ dữ liệu sầu riêng Zenodo, giải quyết triệt để bài toán không đồng nhất kích thước và tần số lấy mẫu giữa hình ảnh, âm thanh và cảm biến.

2. **Thiết lập hệ thống Benchmark toàn diện (Unimodal vs. Multimodal):** Đánh giá độc lập và đặt lên bàn cân so sánh năng lực phân loại của từng phương thức đơn lẻ (RGB, Acoustic Knock, Thermal/Multispectral) so với mô hình hợp nhất Multi-Modal Teacher, làm rõ mức độ đóng góp thực tế của từng nguồn tín hiệu vật lý.
3. **Nâng cao hiệu năng mô hình Vision-Only thông qua Cross-Modal Distillation:** Chứng minh thực nghiệm (qua Ablation Study trên các hệ số α, β, γ và nhiệt độ T) rằng mô hình Student chỉ dùng ảnh RGB sau khi được chưng cất tri thức từ Teacher đạt độ chính xác (Accuracy, Macro-F1) vượt trội rõ rệt so với mô hình Baseline Vision huấn luyện độc lập по phương pháp truyền thống, trong khi vẫn giữ nguyên chi phí suy luận (Latency/FLOPs) cực thấp.
4. **Giải thích mô hình trực quan (Explainable AI - XAI) và Phân tích giới hạn vật lý:** Ứng dụng kỹ thuật Grad-CAM / Attention Rollout để đối chiếu vùng chú ý không gian giữa mô hình ảnh trước và sau khi nhận tri thức từ Teacher, đồng thời phân tích chuyên sâu các trường hợp lỗi (Error Analysis) nhằm chỉ ra giới hạn thực tế khi suy luận độ chín nội tại chỉ qua bề mặt vỏ ngoài.